

Synthèse de revue de littérature

Scoring de risque de crédit — approches, métriques et positionnement du projet

1. Contexte et objectif

Le projet consiste à construire un modèle de Machine Learning capable de prédire le risque de défaut de remboursement d'un emprunteur (classification binaire supervisée), à partir du Loan Default Prediction Dataset (Kaggle) et de ses 18 variables socio-économiques et financières. Cette synthèse rassemble les repères de littérature nécessaires pour cadrer les choix méthodologiques des séances suivantes : quelles familles de modèles utiliser, comment évaluer leur performance, et comment gérer le déséquilibre des classes observé dans le jeu de données.

2. Le scoring de crédit : définition et enjeux

Le scoring de crédit consiste à estimer, pour un emprunteur donné, la probabilité qu'il fasse défaut sur son prêt. C'est un outil central pour les banques et institutions financières, qui l'utilisent pour arbitrer l'octroi de crédit et le risque associé. Historiquement dominé par des méthodes statistiques classiques, le domaine s'est progressivement enrichi de techniques de Machine Learning, capables de capter des relations non linéaires entre les caractéristiques de l'emprunteur (revenu, historique d'emploi, endettement, etc.) et le risque de défaut.

3. Panorama des approches de modélisation

3.1. Modèles statistiques traditionnels

La régression logistique reste le modèle de référence du secteur bancaire. Sa popularité tient moins à sa performance brute qu'à son interprétabilité : chaque variable a un effet monotone et quantifiable sur le risque, ce qui facilite la justification des décisions de crédit auprès des régulateurs (exigences de type Bâle) et des clients. Sa principale limite est de ne pas capter les interactions non linéaires entre variables.

3.2. Méthodes d'ensemble (Random Forest, Gradient Boosting)

Plusieurs études de référence, notamment un benchmark de 41 algorithmes sur huit jeux de données réels, montrent que les méthodes d'ensemble (Random Forest, Gradient Boosting, XGBoost) surpassent de façon assez constante les modèles statistiques classiques en termes de pouvoir prédictif. Elles captent mieux les interactions complexes entre variables, au prix d'une interprétabilité plus faible — un compromis important à documenter dans un contexte bancaire réglementé.

3.3. Approches de Deep Learning

Des travaux plus récents explorent les réseaux de neurones (MLP, CNN) sur des jeux de données de scoring, avec des gains de performance parfois significatifs selon le dataset, mais au prix d'une explicabilité encore plus réduite et d'un besoin de volumétrie de données plus important.

4. Métriques d'évaluation adaptées

Le déséquilibre des classes typique du scoring de crédit (peu de défauts par rapport aux bons payeurs) rend l'accuracy peu pertinente comme métrique unique : un modèle qui prédit systématiquement « pas de défaut » afficherait déjà une accuracy élevée sans aucune valeur prédictive. Les métriques suivantes, standards dans la littérature, seront privilégiées :

Métrique	Définition	Utilité pour le projet
AUC-ROC	Aire sous la courbe ROC (taux de vrais positifs vs taux de faux positifs à tous les seuils).	Mesure globale de la capacité du modèle à distinguer défaut / non-défaut, indépendante d'un seuil de décision.
Gini	$2 \times AUC - 1$. Reformulation de l'AUC très utilisée dans le secteur bancaire.	Standard historique du scoring de crédit, facilite la comparaison avec des modèles existants.
KS (Kolmogorov-Smirnov)	Écart maximal entre les distributions cumulées des scores des bons et mauvais payeurs.	Identifie le seuil de score qui sépare le mieux les deux populations.
Matrice de confusion / Recall	Détail des vrais/faux positifs et négatifs à un seuil donné ; recall = part des défauts correctement détectés.	Essentiel vu le déséquilibre : un faux négatif (défaut non détecté) coûte plus cher qu'un faux positif.

5. Déséquilibre des classes

La distribution de la variable cible **Default** observée sur le dataset (environ 88 % de non-défauts contre 12 % de défauts) est typique du scoring de crédit. La littérature propose plusieurs familles de solutions : le rééquilibrage par sur-échantillonnage de la classe minoritaire (SMOTE, ADASYN), le sous-échantillonnage de la classe majoritaire, l'ajustement des poids de classe dans l'algorithme (**class_weight**), ou encore le choix de seuils de décision adaptés au coût métier des erreurs. Le choix précis sera arbitré à la phase de modélisation (S6), en fonction des performances comparées de ces approches sur les jeux d'entraînement et de validation.

6. Positionnement du projet

Le Loan Default Prediction Dataset (Kaggle) utilisé dans ce projet comprend 255 347 emprunteurs et 18 variables : des caractéristiques numériques (âge, revenu, montant du prêt, score de crédit, ancienneté d'emploi, nombre de lignes de crédit, taux d'intérêt, durée du prêt, ratio d'endettement) et des variables catégorielles (niveau d'éducation, type d'emploi, statut marital, présence d'un prêt hypothécaire, de personnes à charge, motif du prêt, présence d'un co-signataire). Cette richesse de variables, combinant profil socio-démographique et caractéristiques financières du prêt, est cohérente avec les jeux de données étudiés dans la littérature (type German Credit, Home Credit, Taiwan Credit). Le projet suivra une démarche standard du domaine : établir une régression logistique comme modèle de référence interprétable, puis comparer sa performance à des méthodes d'ensemble (Random Forest, Gradient Boosting), en évaluant systématiquement AUC-ROC, Gini et KS plutôt que la seule accuracy.

7. Références

- Dastile, X., Celik, T., & Potsane, M. (2020). Statistical and machine learning models in credit scoring : A systematic literature review. *Applied Soft Computing*.
- Lessmann, S., Baesens, B., Seow, H.-V., & Thomas, L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring : An update of research. *European Journal of Operational Research*.
- Hand, D. J., & Henley, W. E. (1997). Statistical classification methods in consumer credit scoring : a review. *Journal of the Royal Statistical Society*.
- Chen, T., & Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD*.
- Kaggle — Loan Default Prediction Dataset (jeu de données source du projet).

Document préparé pour la Séance 2 (S2) — 18/07/2026. À enrichir au fil du projet (S3 à S9) selon le chronogramme.